Energia que dá Lucro: detecção em tempo real de portas de refrigeração abertas no comércio de bairro

FIAP · Engenharia de Software · 4ES · Global Solution 2026.2 · CitizenTech · Applied Computer Vision

Integrantes

- Gustavo Henrique Santos Bonfim · RM98864
- João Pedro Marques · RM98307
- Kayky Paschoal Ribeiro · RM99929
- Lucas Yuji Farias Umada · RM99757
- Natan Eguchi dos Santos · RM98720

Resumo

Pequenos comércios de bairro mantêm geladeiras, expositores e freezers ligados o dia inteiro, e uma porta esquecida aberta aumenta o consumo de energia sem que o comerciante perceba. Esse desperdício não aparece separado na conta de luz, então raramente é corrigido.

Este trabalho apresenta o componente de visão computacional do produto Energia que dá Lucro. Ele usa a imagem de uma câmera comum para detectar, em tempo real, portas de refrigeração abertas, cronometrar cada abertura, avisar quando o tempo passa de um limite e registrar um evento com a duração e o custo estimado.

Foram gravados 19 vídeos de quatro tipos de equipamento, dos quais saíram 472 imagens anotadas no Roboflow em quatro classes: geladeira aberta, geladeira fechada, freezer aberto e freezer fechado. Com aumento de dados, o conjunto chegou a 1.132 imagens. O modelo YOLO11n, pré-treinado, recebeu ajuste fino por 100 épocas em uma placa de vídeo local.

No conjunto de teste, o modelo atingiu precisão de 0,965, recall de 0,914, mAP50 de 0,955 e mAP50-95 de 0,813, processando cada imagem em 6,1 milissegundos. Em cinco vídeos reservados, nunca vistos no treino, a aplicação identificou corretamente a abertura da porta e gerou um evento em cada um.

O objetivo foi atingido para os equipamentos gravados. A principal limitação é a variedade do conjunto: a maior parte das imagens vem de uma única geladeira doméstica, e ainda não há gravações dentro de um comércio. As métricas de teste também são otimistas, porque as imagens de teste vêm dos mesmos vídeos usados no treino.

Introdução

Pequenos mercados, padarias e lojas de bairro dependem de geladeiras, expositores e freezers ligados o dia inteiro. Uma porta esquecida aberta faz o equipamento trabalhar mais para manter a temperatura, aumenta o consumo de energia e pode comprometer a conservação dos produtos. O comerciante raramente percebe esse desperdício, porque ele não aparece separado na conta de luz.

A energia pesa no caixa desses negócios. Segundo levantamento do Sebrae com 669 pequenos negócios de 14 estados, o gasto com a conta de luz pode chegar a 10% do faturamento da empresa, e metade dos pequenos negócios só se lembra da energia quando a conta chega (SEBRAE, 2024). O mesmo levantamento aponta que a principal barreira para investir em eficiência é a falta de conhecimento ou de confiança na tecnologia, citada por 31% dos empresários, seguida pela necessidade de alto investimento, citada por 28%. Entre as recomendações do Sebrae para reduzir a conta estão o treinamento da equipe e o uso de automação e sensores.

Este trabalho faz parte do produto Energia que dá Lucro, desenvolvido para o desafio CitizenTech da FIAP. O componente de visão computacional usa as câmeras de segurança que a loja já possui para detectar, em tempo real, portas de refrigeração abertas, avisar o comerciante e registrar quanto tempo cada porta ficou aberta e quanto isso custou.

Objetivo

Treinar um modelo de detecção de objetos capaz de identificar, em tempo real, geladeiras e freezers com a porta aberta em imagens de câmeras de pequenos comércios, e transformar essas detecções em alertas e em eventos com duração e custo estimado do desperdício de energia.

Explicação técnica das ferramentas

- **YOLO11 (Ultralytics):** família de modelos de detecção de objetos de estágio único, que localiza e classifica os objetos em uma única passagem pela rede, o que permite uso em tempo real. Foi usado o modelo `yolo11n`, o menor da família, pré-treinado no conjunto COCO.
- **Ajuste fino (transfer learning):** o treino parte dos pesos pré-treinados e os ajusta para as quatro classes do projeto, o que exige muito menos imagens do que treinar do zero.
- **Roboflow:** anotação das caixas, divisão em treino, validação e teste, e aumento de dados.
- **PyTorch com GPU:** execução do treino em uma NVIDIA GeForce RTX 5070 de 12 GB. As 100 épocas levaram cerca de 22 minutos.
- **OpenCV:** leitura da câmera ou do vídeo, extração de quadros e exibição.
- **Pillow:** desenho dos textos sobre o vídeo.

- **Regras de negócio em Python:** associação de cada detecção a um equipamento fixo pela posição da caixa, filtro de oscilações, cronômetro por porta, alerta e geração de eventos.
- **pytest:** testes automáticos das regras e da aplicação.

Metodologia

1. **Definição das classes:** `geladeira_aberta`, `geladeira_fechada`, `freezer_aberto`, `freezer_fechado`. Uma geladeira com freezer conta como dois compartimentos, cada um com a sua caixa e o seu estado.
2. **Coleta:** 19 vídeos de treino, gravados pela equipe, de quatro tipos de equipamento: uma geladeira doméstica com gaveta de freezer embaixo (12 vídeos), um freezer (2 vídeos), um frigobar (2 vídeos) e uma cervejeira vista por uma câmera de segurança (3 vídeos). Outros cinco vídeos foram reservados e não entraram no treino.
3. **Extração de quadros:** uma imagem a cada 0,5 segundo, descartando as quase iguais à anterior e borrando rostos (`src/extrair_frames.py`). Depois da limpeza manual, restaram 472 imagens.
4. **Anotação:** no Roboflow, com caixas cobrindo o compartimento inteiro; porta entreaberta conta como aberta. Todas as 472 imagens têm pelo menos um equipamento anotado.
5. **Divisão e aumento de dados:** 330 imagens para treino, 94 para validação e 48 para teste (70%, 20% e 10%). As imagens foram redimensionadas para 640×640. Cada imagem de treino gerou três versões, com variação de brilho (±20%), exposição (±10%), rotação (±5°) e desfoque (até 1 px), somando 990 imagens de treino e 1.132 no total.

Classe	Treino (com aumento)	Validação	Teste
`geladeira_aberta`	402	45	19
`geladeira_fechada`	501	44	27
`freezer_aberto`	162	7	3
`freezer_fechado`	414	51	25

6. **Treino:** `yolo11n`, imagens de 640 px, 100 épocas, com parada antecipada configurada para 20 épocas sem melhora. A parada antecipada não foi acionada: o treino rodou as 100 épocas.
7. **Análise dos erros:** com o limiar de confiança usado pela aplicação (0,5), o número de detecções do modelo coincide com o número de anotações em 123 das 142 imagens de validação e de teste. A classe mais fraca é `geladeira_fechada` (mAP50 de 0,865 no teste). A matriz de confusão salva pelo treino mostra muitas detecções a mais de `geladeira_fechada` e `geladeira_aberta`, mas elas têm confiança baixa e são descartadas pelo limiar de 0,5.
8. **Aplicação em tempo real:** as detecções passam pelas regras de negócio, que mantêm o estado de cada porta, disparam o alerta depois de 60 segundos e registram o evento

quando a porta fecha.

9. **Validação em vídeos não vistos:** a aplicação foi executada nos cinco vídeos reservados (três da geladeira doméstica e dois da cervejeira pela câmera de segurança). Em todos, a abertura da porta foi detectada e um evento foi gravado. Em um deles, a porta ficou aberta por mais de 60 segundos e o alerta disparou.

Foi treinada uma única versão do modelo. Não houve segunda rodada de coleta e treino.

Exemplos de resultados

Métricas no conjunto de teste (48 imagens)

Precisão	Recall	mAP50	mAP50-95
0,965	0,914	0,955	0,813

Classe	mAP50	mAP50-95
`freezer_aberto`	0,995	0,995
`freezer_fechado`	0,995	0,921
`geladeira_aberta`	0,966	0,698
`geladeira_fechada`	0,865	0,639

O resultado de `freezer_aberto` se apoia em apenas 3 exemplos de teste e não é confiável isoladamente.

Na validação, ao final da última época: precisão de 0,966, recall de 0,937, mAP50 de 0,957 e mAP50-95 de 0,833.

Velocidade

O modelo leva 6,1 ms por imagem na RTX 5070, o equivalente a 164 quadros por segundo. A aplicação completa, com leitura do vídeo, regras e desenho na tela, rodou a cerca de 66 quadros por segundo.

Vídeos reservados

Vídeo	Equipamento detectado	Tempo aberto	Custo estimado
`video13`	freezer-1	21 s	R$ 0,0008
`video14`	expositor-1	19 s	R$ 0,0007
`video15`	expositor-1	17 s	R$ 0,0006
`cervejeira1`	expositor-1	10 s	R$ 0,0004
`cervejeira_alerta`	expositor-1	74 s	R$ 0,0028

No vídeo `cervejeira_alerta`, a porta ficou aberta por 74 segundos. O alerta visual e sonoro disparou aos 60 segundos e permaneceu até a porta fechar.



Alerta disparado com a porta aberta há 1 minuto e 7 segundos



Porta aberta com cronômetro, antes do limite



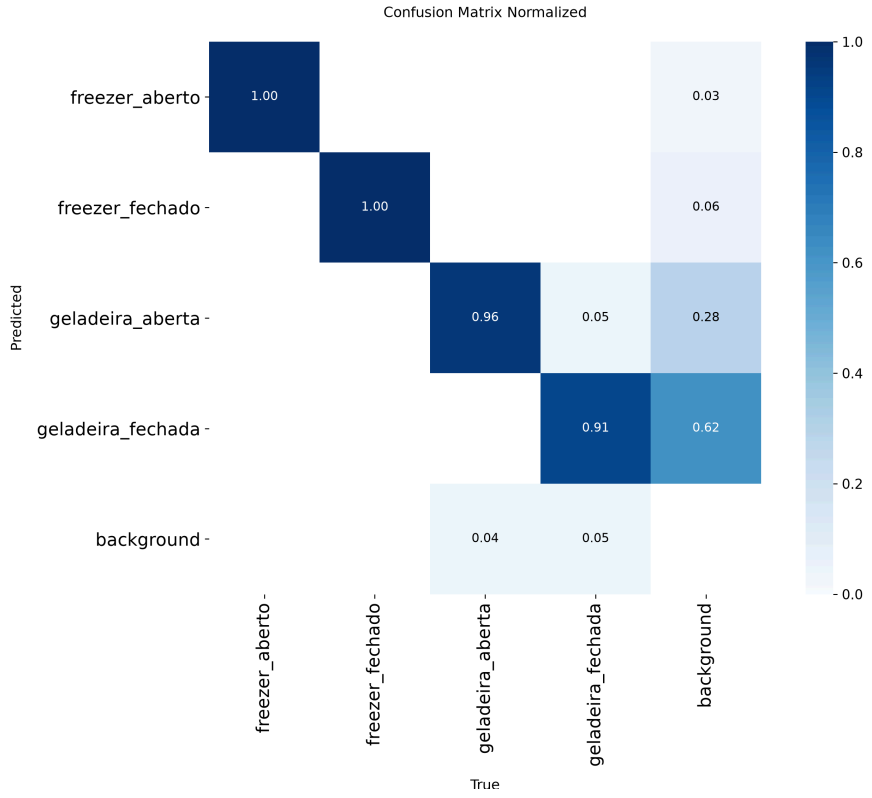
Geladeira fechada e freezer aberto na mesma imagem

Exemplo de evento gravado:

```
{"id": "075e6523-7966-4e52-ac7a-9a3a0b92e642", "loja_id": "padaria-01", "equipamento_id": "freezer-1",
 "tipo": "porta_aberta", "origem": "acv", "inicio": "2026-11-11T19:31:51-03:00", "duracao_s": 21,
 "custo_estimado_rs": 0.0008}
```

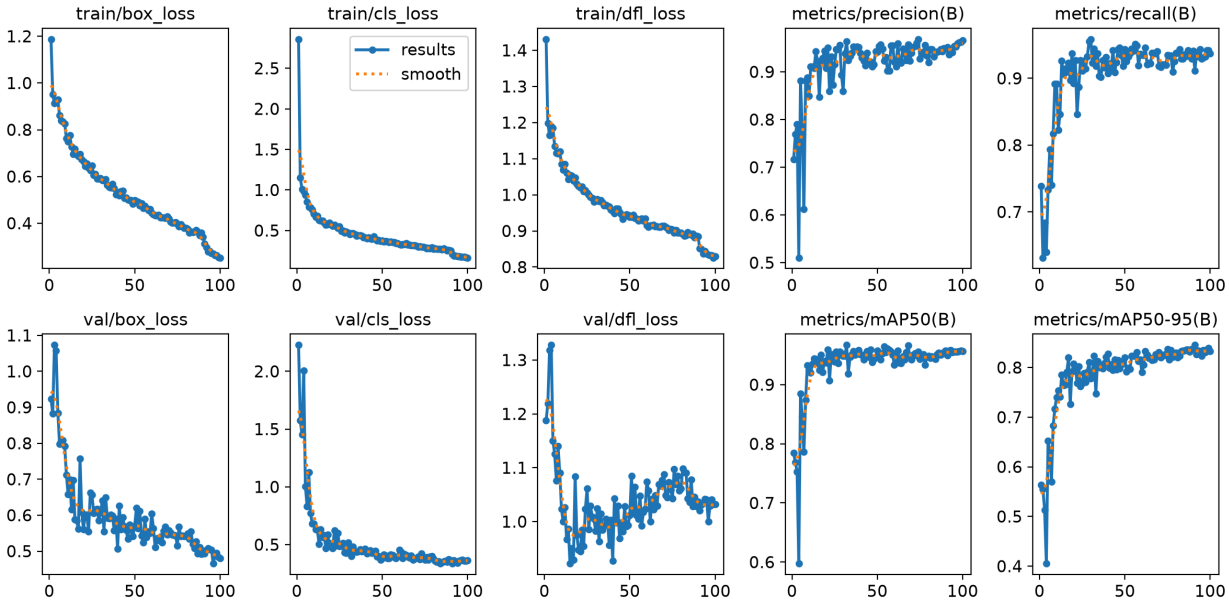

O custo usa parâmetros provisórios de potência, perda e tarifa, definidos em `config.yaml` e sem fonte.

Gráficos do treino

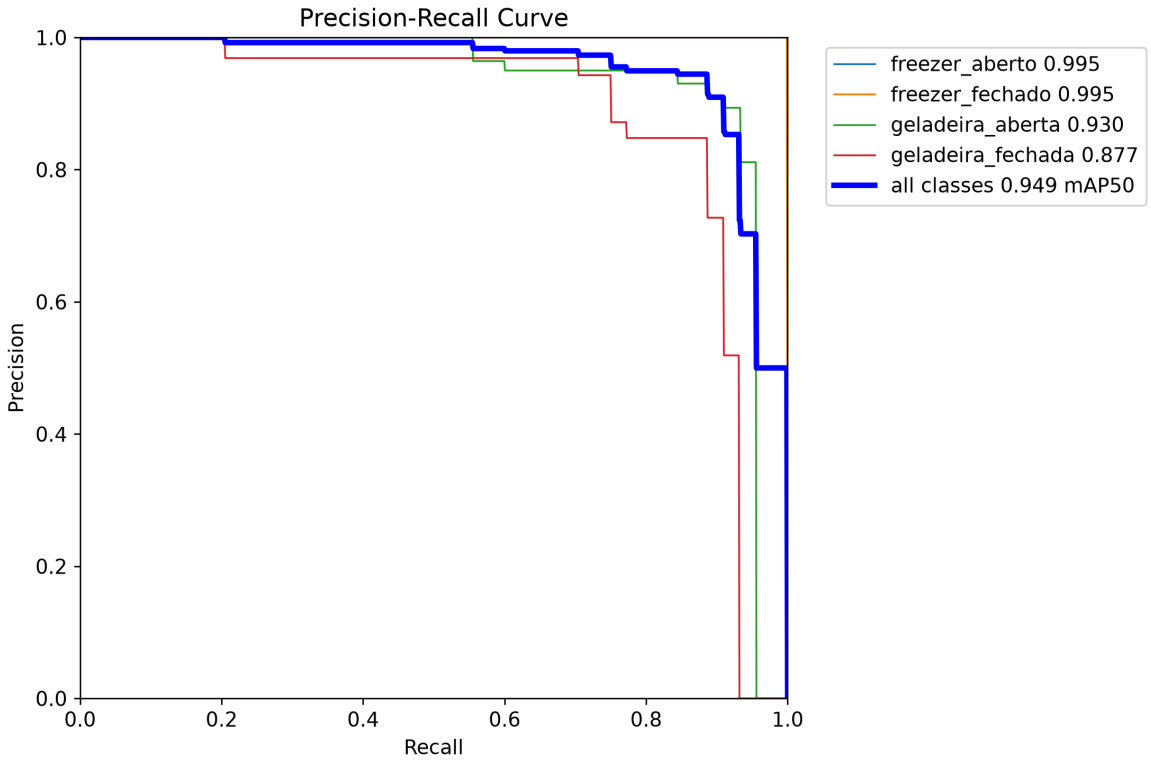


Matriz de confusão normalizada, na validação

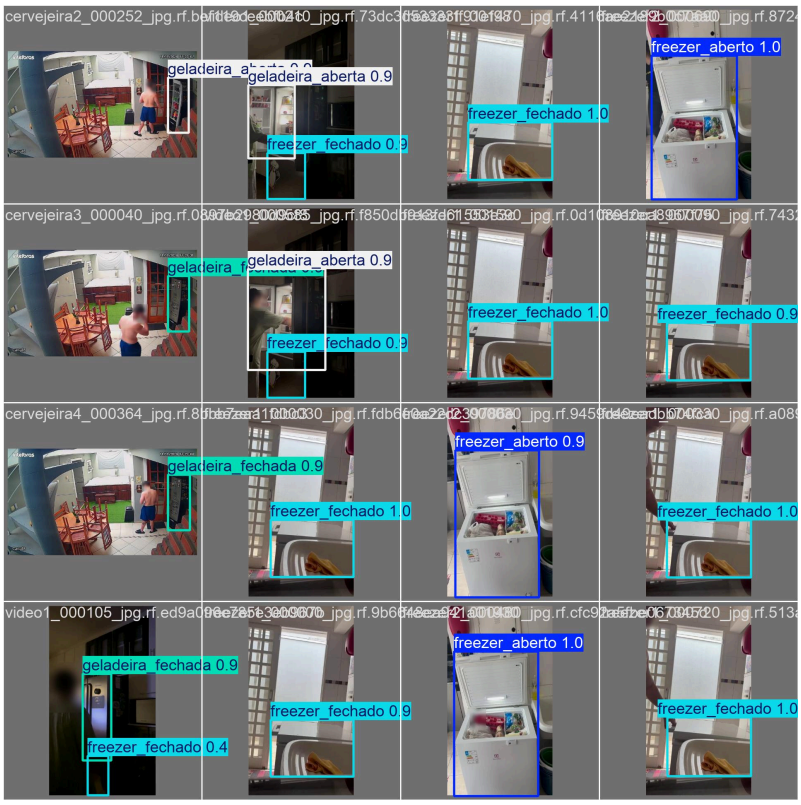
A matriz é calculada com um limiar de confiança muito baixo, por isso mostra detecções a mais de geladeira na coluna de fundo. Com o limiar de 0,5 usado pela aplicação, essas detecções são descartadas.



Curvas de treino e validação ao longo das 100 épocas



Curva de precisão e recall por classe



Detecções do modelo em imagens de validação

Limite da avaliação

As imagens de teste vêm dos mesmos vídeos das imagens de treino, e imagens vizinhas de um vídeo são muito parecidas. Por isso as métricas tendem a ser mais altas do que o desempenho em um local novo, e o resultado nos vídeos reservados também é apresentado.

Conclusão

O objetivo foi atingido para os equipamentos gravados: o modelo detecta os quatro estados com mAP50 de 0,955 no teste, roda muito acima do necessário para tempo real e funcionou nos cinco vídeos que não participaram do treino, incluindo a imagem de uma câmera de segurança.

Limitações:

- **Pouca variedade:** 12 dos 19 vídeos mostram a mesma geladeira doméstica, e não há gravações dentro de um comércio. O desempenho em expositores comerciais é desconhecido.
- **Poucos exemplos de freezer aberto:** 172 no conjunto com aumento, contra 414 a 572 das outras classes.
- **Sem imagens de fundo:** nenhuma imagem do conjunto está sem equipamento, então o modelo pode apontar uma geladeira onde não há.
- **Métricas otimistas:** pelo motivo descrito em "Limite da avaliação".

- **Custo estimado sem calibração:** os parâmetros do cálculo não vêm de medição nem de fonte.

Próximos passos: gravar em dois ou três comércios, incluir imagens sem equipamento, calibrar o custo com medição real de consumo e integrar os eventos ao painel do comerciante e aos alertas por mensagem.

Referências

- JOCHER, G.; QIU, J. Ultralytics YOLO11. 2024. Disponível em: https://github.com/ultralytics/ultralytics.
- Roboflow. Disponível em: https://roboflow.com.
- SEBRAE. Gasto com conta de luz chega a 10% do faturamento do pequeno negócio, aponta Sebrae. Agência Sebrae de Notícias, 29 jun. 2024. Disponível em: https://agenciasebrae.com.br/cultura-empreendedora/gasto-com-conta-de-luz-chega-a-10-do-faturamento-do-pequeno-negocio-aponta-sebrae/. Acesso em: 11 nov. 2026.